

二、研究計畫內容（以 10 頁為限）：

（一）摘要

目前的農地現地調查仰賴人工並且曠日廢時，許多調查結果往往在調查結束前早已過時。如何加速現地調查過程，並確保調查結果之準確率，是本研究主要關注的焦點之一。近年來深度學習於影像辨識方面有諸多成果，監督式學習被廣泛應用於各種模型的訓練，但於監督式學習範疇下的分類模型在訓練過程中往往需要使用大量的標記資料以確保模型的準確率，造成在資料前處理階段需投入大量人力進行資料標記，有些資料集甚至需要該領域的專家進行標記，導致高品質資料集之建構困難重重，進而使分類成效不佳。

有鑑於此，本研究試圖結合半監督式學習(Semi-Supervised Learning, SSL)與生成對抗網路(Generative Adversarial Network, GAN)，並根據 Wasserstein GAN(WGAN)中所提出之演算法對原始生成對抗網路之損失函數與模型結構進行改良，建構半監督式 Wasserstein 生成對抗網路(Semi-Supervised Wasserstein GAN, SWGAN)，一個用於應對少量標記資料並相對穩定的演算法，並將其用於農作物的手機影像分類，辨識作物種類有水稻、青蔥與甘蔗等三類。採用半監督式學習的方式可以在訓練中加入未標記資料，能有效地將大量未標記資料用於擴增訓練集的資料分佈，且得益於生成對抗網路特有的對抗訓練，以及 WGAN 對於原始損失函數的修改，能使生成器更容易擬合至真實資料分佈。此外，本研究會針對 SWGAN 中的分類器進行基準測試，設計一個結構與之相同的捲積類神經網路(Convolutional Neural Network, CNN)，藉此探討標記資料使用比例與 SWGAN 分類器效能的關聯。綜合上述幾點優勢，期望結果除了能用於加速農地現地調查外，亦能夠投入其他領域。

關鍵詞：生成對抗網路、半監督式學習、Wasserstein 距離、農地現地調查

（二）研究動機與研究問題

農業相關的研究以及政策規劃時常需要進行現地調查以獲取相關數據，但過去現地調查的方法需要花費大量人力及時間，調查結果在整體報告出爐時早已過時，如何加速農地現地調查流程以及確保調查結果之準確性便是本研究的目標。農試所(2019)曾與成功大學測量及空間資訊學系合作開發「現地調查影像分類系統」，結合深度學習技術及行車紀錄器進行農作物影像辨識，並且於水稻達到 90% 的準確率，但於葉菜類作物如甘藍卻無法達到預期成效。過去利用類神經網路於作物影像分類能夠達到一定準確率，其準確率取決於該類別的訓練資料多寡，以及整體資料集的標記品質，但由於缺乏專業判釋人員，使特定類別的訓練資料數量分布不均，進而導致資料集不平衡，以及資料標記錯誤導致資料集品質下降等問題。

資料集品質以及標記資料的數量對於以監督式學習訓練之模型影響甚大，因上文提到的限制，使得資料集的準備以及處理成為一項浩大且複雜的工程。有鑑於此，本研究試圖使用半監督式生成對抗網路來應對此問題，並以 Wasserstein 生成對抗網路中提到的改動方式，針對原始損失函數與模型結構進行修改以改善穩定性，此模型由三個類神經網路組成，分別為生成器、共享隱藏層權重的判別器和分類器，其特點有 1.對抗訓練：生成器和判別器採用了非監督式的對抗訓

練，生成器的參數更新完全取決於判別器的反向傳播，使生成器能產生高仿真影像作為訓練資料；2.半監督式學習：模型只需要少量的標記資料便能開始訓練，並且在訓練過程中能有效地運用未標記資料作為其訓練資料，彌補標記資料數量過少的問題；3.權重共享：判別器和分類器的隱藏層權重共享，能使判別器於非監督式學習中萃取的特徵被有效地運用在分類器中；4.穩定性：Wasserstein 生成對抗網路中採取了一系列的措施來提升訓練穩定性，使生成器不容易因判別器過強而遇到梯度消失問題，進而使雙方能更好的擬合至真實資料分布。

(三)文獻回顧與探討

1. 農情調查

我國臺灣地區於民國 36 年開始實施農情調查，洪忠修(2003)指出我國農牧業調查制度的演進主要分為三階段 1.筭路藍縷草創期：此時的調查方法使用耕地圖以及土地臺帳資料，繪製完耕地圖略後便赴現地調查作物生長情形，過程中完全仰賴人工方式統計全臺鄉鎮市資料；2.脫胎換骨期：民國 73 年為因應農業發展，使用 1/5000 大比例尺航照圖並配合求積儀與面積計算板測算各田塊的作物面積，並搭配田間調查人員明確目視每一坵塊利用情形，改變了過去完全依賴自繪耕地略圖的傳統做法，並由於調查制度更新成功，為現今資訊化調查方法打造良好的基礎；3.資料處理資訊化期：主要是資訊系統之建置以及軟體升級，完整中央、縣市與鄉鎮三級的農情調查資訊化系統。

近年來航遙測影像應用於農情調查上逐漸受到重視，運用航遙測影像判釋能進行作物面積計算，但由於國內農作物於同一時間栽培的作物品種複雜，並且相同作物於多時期影像下歷經物候期，使得航遙測影像判釋困難重重，經常產生誤判等問題，於是出現針對判釋率高之作物採航遙測判釋為主，其餘判釋率低的作物以現地調查為輔。農試所曾結合深度學習技術和行車紀錄器進行農作物影像辨識，試圖節省投入至農地現地調查的人力資源，並於水稻達到 90%的準確率，但葉菜類作物如甘藍卻無法達到預期成效，其原因初估為 1. 標記資料來源及品質：單一作物如甘藍的物候期人工判釋需要受到良好訓練的判釋人員來完成，缺乏判釋人員導致標記資料的少量產出，並且有時甚至會出現人工誤判等情形，大大影響模型預測準確率；2.訓練資料數量：延續上一原因，葉菜類作物如甘藍等訓練資料過少，即便使用資料增強也只能達到一定成效。

2. 深度學習於農作物影像辨識

過去基於深度學習於農作物影像辨識的目標大致圍繞在 1.農作物影像分類；2.農作物異常偵測，這兩樣應用對於加速農地現地調查時程以及減少投入人力有相當的助益，但深度學習的高準確率通常取決於訓練資料的數量及品質好壞，由於上文提到的資料標記限制，使得少數作物的標記資料數量不易上升，欲使用少量訓練資料換取高準確率對於深度學習中的監督式學習是一大挑戰。

近年來有許多研究焦距在使用深度學習進行農作物影像辨識，Yang Lu 等(2017)提出使用深層捲積神經網路進行稻作疾病影像的辨識，相較於其他機器學習演算法如支持向量機在 10 種稻作疾病類別的分類上所達到的 91%

準確率，或是粒子群最佳化演算法達到的 88% 準確率，Yang Lu 等所提出的方法成功達到 95% 以上的準確率，實驗結果顯示在標記資料充足的狀況下，深層捲積神經網路的表現較普遍機器學習演算法來的好。

隨著深度學習的蓬勃發展，越來越多人意識到標記資料數量對於監督式學習的影響力不亞於模型結構設計，現實的資料容易取得，但標記資料卻要投入大量人力進行處理，有鑒於此，許多訓練策略被提出用於應對上述問題。Solemane Coulibaly 等(2019)提出使用轉移學習(Transfer Learning)的方式來應對標記資料數量過少的問題，使用於 ImageNet 訓練完成的 VGG16 作為特徵提取器，並使用經過資料增強後的 711 張訓練影像，最後於珍珠粟疾病的辨識達到 95% 以上的準確率。K.Thenmozhi 等(2019)也使用了轉移學習進行作物病蟲害的辨識，使用了 AlexNet、ResNet 和 GoogLeNet 等預訓練模型作為轉移學習的特徵提取器，並搭配資料增強使模型在測試集上達到 95% 以上的平均準確率。

上述文獻所提出的方法均屬於監督式學習的範疇，意味著這些演算法極度依賴高品質且大量的標記資料，雖然有些文獻使用了資料增強(Data Augmentation)，透過調整資料光影、角度、色相及數量來增進資料集品質，但無法否認的是透過資料增強生成的訓練資料是根據原始資料集分布所生成的，對於增加模型的泛化性只能達到一定成效，因此在後續的實驗中，本研究會針對如何增進模型泛化能力等問題進行探討。

3. 生成對抗網路

生成對抗網路(Generative Adversarial Network, GAN)是由 Ian Goodfellow 等(2014)所提出的一種生成模型，該模型由兩個類神經網路組成，分別為生成器(Generator, G)以及判別器(Discriminator, D)，其損失函數如下：

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_z(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

訓練過程如同 G 和 D 之間的對抗遊戲， G 的輸入為符合任一機率分布之向量 \mathbf{z} 並且輸出一個三維矩陣， D 要透過分辨 G 的輸出和真實影像來最大化價值函數 V ， G 則得透過給予 D 錯誤的標籤來最小化價值函數 V ，雙方於參數更新時會交替更新，當更新其中一方的參數時，另一方的參數便會固定。GAN 的優點有 1. 參數更新方式：GAN 的參數更新只會用到反向傳播，不須使用到複雜的馬可夫鍊或近似推理，相較於其他生成模型的訓練較為容易；2. 生成樣本品質：相較於其他生成模型，GAN 能產生出品質更高的樣本，進而提升 D 的準確率以及強健性；3. 表徵學習：GAN 屬於非監督式學習的範疇，透過雙方的對抗訓練，判別器能學習到大量有用的特徵並用於分類。

4. 半監督式學習

半監督式學習(Semi-Supervised Learning, SSL)是一種基於監督式學習和非監督式學習所延伸出的訓練方法，本研究會焦距在由前者所延伸出的半監督式分類(Semi-Supervised Classification)問題上。半監督式學習又分為歸納學習(Inductive Learning)和轉導學習(Transductive Learning)，給予下列假設：

$$D_l = \{(X_i, Y_i)\}_{0 \leq i \leq n}, \quad D_u = \{X_j\}_{n < j \leq n+k}, \quad D_t = \{X_{\text{test}}\}$$

D_l 為一標記資料集合， D_u 為未標記資料， D_t 為測試集資料，且資料數量 $n \ll k$ ，歸納學習就如同我們所熟知的監督式學習，只使用到包含標記的 D_l 進行訓練，而轉導學習則額外用到了 D_u 所提供的特徵。給予兩組相同結

構與參數的模型 $I(x; \theta_I)$ 與 $T(x; \theta_T)$ ，分別對其進行歸納學習與轉導學習，最後兩者再去對 D_t 進行預測，由於使用轉導學習的 T 在訓練過程中使用了 D_u 作為訓練資料，使 θ_T 學習到 D_u 的表徵，在相同情況下 T 於測試集 D_t 的表現會優於 I ，說明採取轉導學習對於預測是有正向幫助的，使用額外的未標記資料增進模型預測結果，這正是半監督式學習所擁有的優勢。

5. 半監督式對抗訓練

特徵學習(Representation Learning)是模型學習資料特徵的技術集合，特徵的學習與提取一直是非監督式學習領域所關注的主題之一，許多演算法如 Pascal Vincent 等(2010)提出的堆疊式降噪自編碼器，和 Antti Rasmus 等(2015)所提出的階層式網路結構，都被證實能在非監督式學習的情況下學習到良好的特徵。此外，在 Alec Radford 等(2016)所提出的深層捲積生成對抗網路(Deep Convolutional GAN, DCGAN)中便驗證了判別器在非監督式訓練的過程中所學到的特徵能有效地被運用在監督式分類的任務，將 DCGAN 的判別器作為特徵提取器並且和 L2-SVM 結合作訓練，相較於 K-means 等非監督分類演算法，以 DCGAN 為基礎的分類器於 CIFAR-10 資料集的分類達到 82.8% 的準確率，高於所有使用 K-means 為基礎的演算法。

半監督式學習雖然能使用大量未標記資料，但如何設計一套能使用這些未標記資料的演算法也是重點之一，Tim Salimans 等(2016)便提出將半監督式學習和生成對抗網路結合的概念，這個方法強迫其判別器輸出總共 $K+1$ 類的預測類別， K 為我們欲預測的類別數量，而由生成器所生成的偽資料則被歸類為 $+1$ 類，對於判別器的訓練方法則分為兩種模式，分別為監督模式和非監督模式，前者如同監督式訓練給予判別器真實的標記資料，後者則給予未標記的真實資料以及偽資料。

半監督式生成對抗網路(Semi-Supervised Generative Adversarial Network, SGAN)是由 Augustus Odena(2016)提出並驗證，透過比較 SGAN 的分類器和單獨的捲積神經網路(Convolutional Neural Network, CNN)於 MNIST 的預測成效，成功地驗證了於少量標記資料數量下，SGAN 的準確性能優於 CNN。Hamideh Kerdegari 等(2019)也使用 SGAN 進行 weedNet 無人機多光譜影像資料集的分類，並且於 50% 標記資料的情況下達到 85.7% 的作物辨識準確率以及 86.5% 的雜草辨識準確率，相較於其他使用 100% 標記資料的 CNN 能達到相對好的準確率，因此本研究試圖利用 SGAN 對抗訓練的特點增強分類器的準確率與泛化能力。

6. Wasserstein 生成對抗網路

原始生成對抗網路於 2014 年誕生之始，便有著以下幾點缺陷 1. 梯度消失：GAN 的損失函數最終能推導成 JS-divergence 的形式，若從真實資料分布和生成資料分布中採樣出的資料沒有重合，會使生成器容易面臨梯度消失問題，而當兩個資料分布是高維空間中的低維流形時，採樣重疊率為零的機率近似於一；2. 梯度不穩定與模式崩潰：生成器最小化函數矛盾，同時要最小化兩個資料分布的 KL-divergence，又得最大化兩個資料分布的 JS-divergence，這矛盾導致梯度不穩定，並導致生成器產生的樣本缺乏複雜多樣性，與本研究欲提升模型泛化能力的目標背道而馳。

SGAN 便是基於 GAN 的損失函數，並修改模型結構與訓練演算法而來

的，這使得 SGAN 時常於訓練過程中崩潰，過強的判別器導致的梯度消失會使生成器在擬合至真實資料分布前便提早結束訓練，同時使分類器無法順利學習真實資料分布，導致 SGAN 的訓練非常困難。

於是 Martin Arjovsky 等(2017)便針對 GAN 的損失函數以及模型結構進行修改並驗證有效性，提出 WGAN，有以下幾點改動 1.Wasserstein 距離：又稱 EM-distance，相較於上文提到的 JS 與 KL-divergence，即使兩個資料分布沒有重疊，Wasserstein 距離依然能反映它們之間的距離，並因其計算兩個分布間的距離時不會傾向於極端，使模型雙方不易因極端的梯度而出現梯度消失，公式如圖一；2.判別器改線性輸出：因 Wasserstein 距離相當於迴歸問題，於是須捨棄 GAN 原先使用的 sigmoid 激發函數並改用線性輸出；3.參數更新限制：為確保訓練過程中判別器不會完全壓制生成器，故限制判別器參數更新量。以上改動均被證實對於提升 GAN 訓練穩定性有重大貢獻，於是本研究採用其方法，並結合 SGAN 以提升穩定性。

$$W(\mathbb{P}_r, \mathbb{P}_g) = \inf_{\gamma \in \Pi(\mathbb{P}_r, \mathbb{P}_g)} \mathbb{E}_{(x,y) \sim \gamma} [\|x - y\|]$$

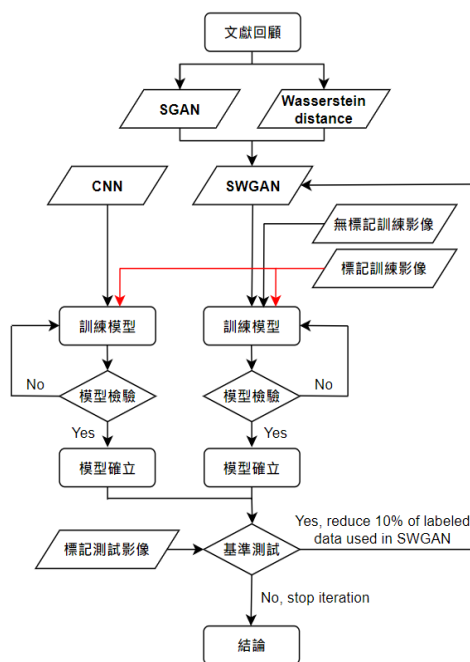
圖一、Wasserstein 距離公式

7. 小結

由上述文獻能發現，生成對抗網路是個相對新興的研究領域，並且因其模型與訓練方法的特殊性，使其能與半監督式學習的訓練方法進行結合，本研究主要目標為針對因無法取得足夠標記資料所衍生出的分類器成效不佳問題進行改善，並且根據 WGAN 中提出的方法對 SGAN 進行改良，試圖改善原始 SGAN 訓練困難等問題，並將其應用於農作物現地調查上。然而，筆者於梳理文獻時發現大多數研究僅做到將模型應用於特定領域上，鮮少有研究著墨於生成對抗網路對分類器帶來的優勢，本研究除了將 SGAN 運用於農作物現地調查上，也會透過基準測試來比較 SGAN 分類器與 CNN 於相同任務上所達成的準確率與泛化能力，藉此比較半監督式生成對抗網路相較於監督式學習模型具有的優勢。

(四)研究方法及步驟

本研究欲將深度學習技術應用於農作物現地調查，且試圖將 SGAN 搭配 Wasserstein 距離，提出一個能使用少量標記資料達到高準確率並具有良好泛化能力之模型 SWGAN。此外，本研究同時設計一對照組模型 CNN，此模型結構與 SWGAN 之分類器相同，並於標記資料集上進行訓練，待預測準確率達到本研究設定之閾值後便留作效能比較使用，接著使用相同的標記資料集與額外未標記資料集訓練 SWGAN，每次訓練結束後便與 CNN 進行基準測試，



圖二、研究流程圖

若 SWGAN 分類器優於 CNN，則通過基準測試，並將 SWGAN 所使用之標記資料減量 10% 並重新訓練，持續迭代直到 SWGAN 分類器於基準測試無法優於 CNN 時便停止所有訓練，藉此探討標記資料使用量對於 SWGAN 分類器準確率之影響。研究流程如圖二所示。

1. 資料集清洗與劃分

本研究暫定的資料集類別分別為水稻、甘蔗與青蔥，限制為一張影像只會有一個類別，並於標記完成後將影像調整至 $(3, 256, 256)$ 之尺寸，以配合判別器與分類器之輸入結構。在資料集準備階段，首先給予以下定義：

$$D_{size} \in \{i | i \in N\}, \quad D_{labeled} = \{(X_i, Y_i)\}_{0 < i < n}^n, \quad D_{unlabeled} = \{X_j\}_{n < j < n+k}^{n+k}$$

本研究預計使用手機影像作為訓練與測試集資料，首先將資料集依照每個類別 10% ($n = D_{size} * 10\%$) 與 90% ($k = D_{size} * 90\%$) 的比例進行劃分，前者為標記資料集 $D_{labeled}$ ，後者為未標記資料集 $D_{unlabeled}$ 。接著給予 $T_{size} = \{i | i \in N < n\}$ ，並只需對 D_l 少量的人工標記，並將 D_l 根據每個類別 60% ($m = T_{size} * 60\%$)、25% ($t = T_{size} * 25\%$) 與 15% ($r = T_{size} * 15\%$) 的比例劃分為訓練集 D_{train} 、驗證集 D_{val} 與測試集 D_{test} 。

$$D_{train} = \{(X_i, Y_i)\}_{0 < i < m}^m, \quad D_{val} = \{(X_j, Y_j)\}_{m < j < m+t}^{m+t}, \quad D_{test} = \{(X_h, Y_h)\}_{m+t < h < m+t+r}^{m+t+r}$$


當雙方訓練結束後便進入基準測試階段，SWGAN 的分類器若於基準測試勝過 CNN，便會針對 D_{train} 進行每個類別 $m * 10\%$ 的減量，並重新開始訓練 SWGAN，直到 CNN 於基準測試中獲勝。

2. SWGAN 與對照組模型設計

本研究所設計之模型主要分為兩部分：

(1) SWGAN：由生成器 $G(z; \theta_g)$ 、判別器 $D(x; \theta_s, \theta_d)$ 與分類器 $C(x; \theta_s, \theta_c)$ 所組成， G 為一卷積神經網路，輸入 z 是維度 (100) 並符合高斯分布隨機生成之向量，輸出則是維度 $(3, 256, 256)$ 之 x 矩陣，並且使用 tanh 作為 G 輸出層的激發函數。 D 與 C 為卷積神經網路，採部分權重共享的結構， θ_s 為兩模型共享之參數， θ_d 與 θ_c 則為獨立參數，兩模型各自具有獨立的輸出層， D 的輸出是維度 (1) 之向量，並且因應損失函數更換， D 輸出層不使用激發函數， C 的輸出則是維度 (3) 之向量，並且使用 softmax 作為輸出層激發函數。相較於原始 SGAN，本研究採用部分參數共享能使 θ_d 與 θ_c 更專精於各自的分類任務上，藉此降低 SWGAN 訓練時對 C 帶來的噪音，使 C 能達到更高的準確率。

(2) 對照組模型：對照組模型 $S(x; \theta_{sa})$ 是結構與 C 相同之模型，兩者的差別在於 S 並沒有參數共享層，意味著 S 無法享有 G 與 D 於對抗訓練所學習到的表徵 θ_s 。本研究主要探討的目標就是共享層參數 θ_s 是否能增強模型的準確率與泛化能力。SWGAN 模型結構示意圖如圖三所示，正式模型結構需待實作結束後才能提出。



圖三、SWGAN 模型結構示意圖

3. SGAN 演算法更動

本研究根據 WGAN 提出的部分修改方法，針對 SGAN 演算法進行改良，本研究採納的更動有三：

(1)更改損失函數：本研究根據 WGAN 中所提出的 Wasserstein 距離，針對 SGAN 的損失函數進行更動，更動後的損失函數如圖四。

(2)更改判別器激發函數：由於將損失函數更改為 Wasserstein 距離後，此時 D 的任務就變為預測真實與生成資料分布之間的 Wasserstein 距離，屬於迴歸問題，因此需將原本作為二分類任務的 sigmoid 激發函數替換為線性輸出。

(3)限制判別器參數更新量：為使判別器輸出分布呈現 1-Lipschitz 連續，於是需針對判別器參數更新量進行限制，使其能與生成器於訓練過程中勢均力敵。此部分預計採用 WGAN 中提出的 weight clipping 方法進行實作。

$$-\mathbb{E}_{x \sim P_g} [f_w(x)]$$
$$\mathbb{E}_{x \sim P_g} [f_w(x)] - \mathbb{E}_{x \sim P_r} [f_w(x)]$$

圖四、更動後的損失函數(上下分別是生成器與判別器的損失函數)

4. 訓練演算法

此階段為本研究所設計之 SWGAN 模型訓練流程，首先使用 m 筆標記資料對 C 與 S 進行梯度下降，再來使用 m 筆之未標記資料和隨機生成之資料對 D 進行梯度下降，最後隨機生成 $2m$ 筆向量對 G 進行梯度下降，以上操作均進行完畢便進入基準測試，若 C 的準確率小於 S 便結束實驗。

Algorithm 1 Model training algorithm

Input: I , number of iteration of D . J , number of iteration of G .

Input: m , batch size of a minibatch.

```
1: for number of iterations do
2:   Sample minibatch of data from  $D_{train}$  with size  $m$ .
3:   Perform gradient descent to  $(\theta_s; \theta_c) / \theta_{sa}$ .
4:   for  $i = 1$  to  $I$  do
5:     Sample minibatch of data from  $D_{unlabeled}$  with size  $m$ .
6:     Sample  $m$  noise  $z$  from gaussian distribution and feed into  $G$  to produce  $m$  x.
7:     Perform gradient descent to  $(\theta_s; \theta_d)$ .
8:   end for
9:   for  $j = 1$  to  $J$  do
10:    Sample  $2m$  noise from gaussian distribution.
11:    Perform gradient descent to  $\theta_g$ .
12:   end for
13: end for
```

5. 基準測試方法

本研究主要針對 SWGAN 之分類器 C 與獨立 CNN 模型 S 進行基準測試，雙方均於先前定義之 D_{test} 進行測試，根據總體分類結果計算 Overall accuracy 與 Kappa coefficient 等指標，並根據單一類別分類結果產生混淆矩陣，藉此探討模型於各類別之分類情況。

若 C 於基準測試中的 Overall accuracy 贏過 S ，則對標記資料集進行 10% 的減量，在重新訓練 C ，直到 C 無法達到與 S 相同的性能時便停止訓練與基

準測試。

本研究之預期執行進度如表一：

表一、研究預期執行進度表

計畫進度 / 月份	7 月	8 月	9 月	10 月	11 月	12 月	1 月	2 月
文獻探討與補充								
資料清洗與標記								
模型開發								
模型訓練與調參								
基準測試								
撰寫成果報告								

(五)預期結果

1. 本研究建立出的模型能降低標記資料使用量，解決因無法取得足夠標記資料所衍生出的分類器成效不佳問題，從而提升模型投入農作物現地調查的準確率，並且模型泛化能力優於 CNN。
2. 本研究提出的方法除能被用於農作物現地調查外，也能應用於農業生態領域，進行作物與物種的分類。
3. 本研究提出的方法能夠被應用於標記資料不易取得之領域，譬如醫療與疾病辨識領域等標記資料產製較困難之領域。

(六)參考文獻

學術論文：

- 洪忠修 (2003)。我國農牧業農情調查之檢討與展望。農政與農情，第 135 期。
- Arjovsky, M., Chintala, S., & Bottou, L. (2017). Wasserstein gan. *arXiv preprint arXiv:1701.07875*.
- Coulibaly, S., Kamsu-Foguem, B., Kamissoko, D., & Traore, D. (2019). Deep neural networks with transfer learning in millet crop images. *Computers in Industry*, 108, 115-120.
- Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. In *Advances in neural information processing systems* (pp. 2672-2680).
- Kerdegari, H., Razaak, M., Argyriou, V., & Remagnino, P. (2019). Semi-supervised gan for classification of multispectral imagery acquired by uavs. *arXiv preprint arXiv:1905.10920*.
- Odena, A. (2016). Semi-supervised learning with generative adversarial networks. *arXiv preprint arXiv:1606.01583*.
- Rasmus, A., Berglund, M., Honkala, M., Valpola, H., & Raiko, T. (2015). Semi-supervised learning with ladder networks. In *Advances in neural information processing systems* (pp. 3546-3554).
- Radford, A., Metz, L., & Chintala, S. (2015). Unsupervised representation learning with deep convolutional generative adversarial networks. *arXiv preprint arXiv:1511.06434*.
- Salimans, T., Goodfellow, I., Zaremba, W., Cheung, V., Radford, A., & Chen, X. (2016). Improved techniques for training gans. In *Advances in neural information processing systems* (pp. 2234-2242).
- Vincent, P., Larochelle, H., Lajoie, I., Bengio, Y., Manzagol, P. A., & Bottou, L. (2010). Stacked denoising autoencoders: Learning useful representations in a deep network with a local denoising criterion. *Journal of machine learning research*, 11(12).
- Zhu, X., & Goldberg, A. B. (2009). Introduction to semi-supervised

learning. *Synthesis lectures on artificial intelligence and machine learning*, 3(1), 1-130.

網路資料：

農傳媒 (2019)。農試所開發作物影像判釋系統，行車紀錄器就能做農地調查。取自：<https://www.agriharvest.tw/archives/6354>

(七)需要指導教授指導內容

1. 資料清洗與資料集建構時給予建議。
2. 研究過程中給予演算法與觀念修正。
3. 協助模型驗證方法的分析。